

Agente operativo con IA y RAG para consultas de stock, pedidos, políticas y reportes

Propuesta de solución, arquitectura de integración, selección tecnológica y prueba de concepto funcional

Jefferson Cuadrado
Octubre de 2026



Prueba de concepto: dato vivo del ERP, política citada y veredicto en una sola respuesta

Cuatro bloques, de la necesidad de negocio a la prueba de concepto

01

Propuesta de Solución

¿Qué problema de negocio resolvemos y con qué enfoque?

Problema, impacto y propuesta de agente con RAG

4 min

02

Arquitectura e Integración

¿Cómo interactúan usuario, agente, conocimiento y ERP?

Arquitectura de referencia, flujo BPMN e integración con el ERP

6 min

03

Selección Tecnológica & Agentes

¿Con qué tecnología y cómo se evitan las alucinaciones?

Frameworks, modelos, prompt engineering y evaluación

6 min

04

Demostración Práctica (PoC)

¿Funciona con servicios reales y con qué resultados?

Atlas en vivo, escenarios, métricas y ruta a producción

7 min

Las secciones 1 a 3 describen la solución como propuesta de arquitectura; la sección 4 presenta Atlas, la prueba de concepto que la materializa

01

Propuesta de Solución

El problema de negocio, su impacto y una solución estructurada basada en un agente de IA con RAG

1 · Propuesta de Solución

2 · Arquitectura e Integración

3 · Selección Tecnológica & Agentes

4 · Demostración Práctica (PoC)

Las consultas manuales convierten a los expertos en un cuello de botella

Cuatro tipos de consulta, dos naturalezas de fuente

Stock de productos

Dato transaccional vivo

ERP · inventario por bodega

Estado de pedidos

Dato vivo y con propietario

ERP · pedidos e historial

Validación de políticas

Conocimiento normativo

Documentos versionados

Resúmenes de reportes

Agregación de datos

ERP · ventas y operaciones

Causa raíz

Cada respuesta exige combinar datos que cambian a cada minuto con normas estables, y hoy solo una persona sabe dónde buscar ambos y qué puede ver cada solicitante

Impacto actual

Demora respuestas en horas, atadas a la disponibilidad de quien sabe buscar

Inconsistencia la misma pregunta recibe respuestas distintas según quién responda

Sin trazabilidad no queda registro de qué se respondió, con qué fuente ni a quién

Coste de oportunidad perfiles expertos dedicados a consultas repetitivas

Objetivos medibles (línea base supuesta)

≤ 8 s

respuesta p95

hoy 2 a 4 h

≥ 80 %

sin intervención

hoy 0 %

100 %

datos vivos exactos

hoy sin medir

Un agente orquestador responde cada consulta desde su fuente de verdad

No todo es RAG: cinco rutas según la evidencia necesaria

DATA

Herramientas sobre el ERP

«¿Cuánto stock queda del producto X en la bodega principal?»

RAG

Políticas con cita verificable

«¿Cuál es el plazo para devolver un producto con defecto?»

MIXED

Dato vivo + política

«¿Todavía puedo devolver mi pedido?»

DIRECT

Sin datos de negocio

Saludos y preguntas sobre el propio asistente

ABSTAIN

Sin evidencia: deriva

«¿Cuál es la política de teletrabajo para proveedores?»

Componentes de la solución

1

Agente orquestador

un solo agente enruta, reúne evidencia, redacta y verifica

2

Herramientas sobre el ERP

consultas tipadas con los permisos del solicitante

3

RAG sobre políticas

búsqueda semántica en documentos versionados, con cita

4

Abstención y derivación

sin evidencia suficiente, lo declara y escala a una persona

5

Canales y trazabilidad

web y mensajería con el mismo agente; cada turno se registra

Principio rector el LLM no es la fuente del dato: enruta, razona sobre evidencia recuperada y redacta. Cifras desde el ERP; normas desde documentos citados

02

Arquitectura e Integración

Cómo interactúan el usuario, el agente, la base de conocimiento y las APIs del ERP

1 · Propuesta de Solución

2 · Arquitectura e Integración


3 · Selección Tecnológica & Agentes

4 · Demostración Práctica (PoC)

La arquitectura separa canales, orquestación, conocimiento y ERP



Cada turno decide su ruta, reúne evidencia y se verifica antes de responder



El ERP se integra con herramientas tipadas tras un gateway, no con Text-to-SQL

Patrón de integración en capas



Cambiar de ERP es escribir otra implementación del gateway: herramientas, prompts y grafo no cambian

Herramientas tipadas frente a Text-to-SQL

Criterio	Herramientas tipadas	Text-to-SQL
Permisos	los aplica el servidor en cada llamada	dependen de la consulta que escriba el modelo
Seguridad	argumentos validados; sin SQL generado	superficie de inyección y fuga entre clientes
Exactitud	cálculos deterministas en el servicio	cifras sujetas a errores de la consulta
Auditoría	llamada y argumentos en la traza	consultas libres, difíciles de revisar
Flexibilidad	acotada al catálogo de herramientas	alta, para analítica exploratoria

Decisión herramientas tipadas para la operación; Text-to-SQL solo como evolución para analítica, sobre una réplica y con un rol de solo lectura

03

Selección Tecnológica & Agentes

Frameworks, modelos y estrategias de prompt engineering y orquestación para respuestas precisas

1 · Propuesta de Solución


2 · Arquitectura e Integración

3 · Selección Tecnológica & Agentes

4 · Demostración Práctica (PoC)

LangGraph aporta el control explícito del flujo que exige un agente auditable

Matriz ponderada (1 a 5) · valoración para este caso



Criterios y pesos

- | | |
|---|---|
| 25 % Control del flujo y traza por paso | 20 % Integración con backend y permisos |
| 15 % Control fino del LLM | 15 % Pruebas y versionado |
| 15 % Pocas piezas móviles | 10 % Licencia y madurez |

Cada herramienta tiene su lugar

LangChain / LangGraph
grafo de estados explícito, en el proceso del backend, con traza por nodo y pruebas. LangChain aporta los conectores

LlamaIndex
fuerte en ingesta y RAG documental; aquí el reto es la orquestación con el ERP

CrewAI
equipos de agentes colaborativos; un solo agente es más rápido y auditable

Dify
prototipado low-code con RAG; deja permisos y verificación fuera del backend

n8n
automatización e integraciones; útil para notificaciones, no como núcleo del agente

Modelos acotados y nueve controles cierran el paso a la alucinación

Modelos

LLM de chat

function calling nativo y salida estructurada; en la PoC, gemini-3.5-flash-lite

Embeddings

multilingües, 768 dimensiones; gemini-embedding-2

Re-ranker

cross-encoder multilingüe en CPU (ONNX), para el modo híbrido

LLM juez

evaluación offline; gemini-3.1-flash-lite en el nivel gratuito

Proveedor intercambiable por configuración: un perfil superior se activa por variables de entorno, tras repetir la evaluación

Prompt engineering y orquestación: nueve controles

1 Fuentes separadas

cifras solo de herramientas;
normas solo del RAG

2 Función forzada

al enrutar, el LLM no responde
de memoria

3 Salida estructurada

esquema JSON validado antes
de mostrar

4 Evidencia delimitada

contexto y datos marcados
como datos, no órdenes

5 Citas literales

cada cita existe en el
fragmento recuperado

6 Verificación numérica

toda cifra debe estar en la
evidencia

7 El LLM no calcula

totales, fechas y días los
calcula el servidor

8 Abstención

sin evidencia suficiente, lo
declara y deriva

9 Prompts versionados

con ejemplos, en el repositorio
y evaluados

La calidad se demuestra con un examen reproducible, no con impresiones

1 Conjunto dorado

36

preguntas del negocio con respuesta conocida

- Ruta esperada por pregunta
- Secciones relevantes por documento
- Valores exactos en las de datos
- 5 sin respuesta: ¿se abstiene?

Ni preguntas ni umbrales se ajustan para aprobar

2 LLM como juez (Ragas)

Fidelidad

¿todo lo afirmado se deduce del contexto?

≥ 0,90

Relevancia de la respuesta

¿responde lo que se preguntó?

≥ 0,85

Precisión del contexto

¿los fragmentos útiles aparecen primero?

≥ 0,80

3 Métricas de recuperación

Hit Rate@k

Precision@k

Recall@k

MRR

nDCG

Deterministas, sin LLM: ¿aparece la sección correcta y en qué puesto? Base de una ablación de 24 combinaciones de fragmentación, modo de búsqueda y número de resultados

4 Verificación en cada respuesta, también en producción

Citas

copiadas tal cual del fragmento

Cifras

cada número está en la evidencia

1.er fallo


se regenera una sola vez

2.º fallo

se abstiene y deriva

La búsqueda densa superó a la híbrida en este corpus y se eligió con datos

Recuperación con fragmentación estructural y k = 5



Densa: busca por significado con embeddings. **Híbrida:** suma palabras clave y reordena con un re-ranker

Ablaciones 63 (densa) y 72 (híbrida con re-ranking), 22 preguntas con secciones relevantes

Efecto de extremo a extremo (corrida 77 → 78)

Exactitud de enrutamiento	0,833 → 0,889
Datos vivos exactos	0,636 → 0,818
Falsa abstención	0,226 → 0,161
Latencia p95 del turno	17,0 s → 6,0 s

Contrapartida declarada sin re-ranker no hay umbral de corte; la abstención depende de que el generador declare evidencia insuficiente. La híbrida sigue disponible por configuración. La abstención correcta se mantuvo en 1,000 (5 de 5)

04

Demostración Práctica (PoC)

Atlas: la prueba de concepto que materializa la propuesta, con servicios reales y métricas medidas


1 · Propuesta de Solución

2 · Arquitectura e Integración

3 · Selección Tecnológica & Agentes

4 · Demostración Práctica (PoC)

Atlas materializa la propuesta en un prototipo funcional de extremo a extremo



Lectura del caso MIXED

ERP: entrega el 2026-09-20, 14 días transcurridos. **Política:** plazo general de 30 días, sección 3.1. **Veredicto:** «Cumple», con marca de fecha y hora de la consulta


De la propuesta a la implementación

Componente	En Atlas
Canales	SPA React y bot de Telegram; correo de respaldo
Acceso	API REST Django 5.2 con JWT y permisos por rol
Agente	grafo LangGraph de una pasada en el backend
LLM	gemini-3.5-flash-lite (nivel gratuito)
Vector DB	PostgreSQL con pgvector (HNSW) e índice léxico
ERP	ErpGateway sobre un ERP simulado
Observabilidad	panel con trazas, tokens, costo y latencia

409 pruebas de backend y 62 de frontend en verde; sin llamadas a la API en la suite por defecto

Los nueve escenarios del requerimiento se superaron contra servicios reales

#	Escenario	Evidencia
1	Stock con datos vivos	DATA · 142 unidades, iguales a la base, con fecha y hora
2	Pedido propio y ajeno	el ajeno responde igual que uno inexistente
3	Política con cita	RAG · sección 5.2, versión 2.0, frase literal
4	Devolución con dato y política	MIXED · 14 días, veredicto «Cumple», sección 3.1
5	Resumen de ventas a Telegram	mensaje recibido en el teléfono
6	Tema fuera de la base	abstención con oferta de derivar
7	Respaldo por correo	sin Telegram o con el bot bloqueado
8	Intento de inyección	solo los 6 pedidos del propio cliente
9	Panel de administración	traza, tokens, costo y latencia por etapa



Traza de un turno MIXED en el panel de administración

9 de 9

escenarios superados el 2026-10-04 contra Gemini, Telegram y EmailJS reales; el 2 se repitió tras corregir el desfase horario

Cumple en fidelidad, recuperación y latencia; tres brechas quedan declaradas

Examen de 36 preguntas · corridas 78 (con juez) y 80 (sin juez)

0,931

Fidelidad

Cumple · objetivo $\geq 0,90$

0,896

Relevancia

Cumple · objetivo $\geq 0,85$

1,000

Hit Rate@5

Cumple · objetivo $\geq 0,90$

5,1 s

Latencia p95

Cumple · objetivo ≤ 8 s

0,944

Enrutamiento

Brecha · objetivo 0,95 ·
34/36

0,909

Datos vivos

Brecha · objetivo 100 % ·
10/11

0,799

Precisión de contexto

Brecha · objetivo 0,80

0,0021

USD por pregunta

tarifa de referencia

Riesgos y mitigación

Inventar datos o políticas

nueve controles y examen con umbrales

Inyección de prompts

permisos en el servidor, datos delimitados

Cuotas y modelo ligero

perfil superior por variables, tras reevaluar

Ruta a producción sin cambiar la arquitectura

- ERP real: nueva implementación del gateway (REST u OData)
- SSO corporativo (OIDC o SAML) con roles por grupo
- Colas para ingesta y notificaciones; webhook de mensajería
- Nube gestionada y el examen como puerta en integración continua

Las brechas vienen de controles posteriores al enrutamiento; data-02 se corrigió después y no se ha vuelto a medir. Costo real cero en el nivel gratuito. No se ajustaron preguntas ni umbrales.

IA

Preguntas

Gracias por su atención. Tres ideas para la conversación:

1

El LLM no es la fuente del dato

Cifras desde herramientas del ERP; normas con cita verificable

2

Arquitectura de piezas sustituibles

Agente orquestador, base vectorial y ERP tras un gateway

3

Medido y con brechas declaradas

Nueve escenarios reales superados y un examen reproducible

Glosario de métricas de evaluación

Hit Rate@k TASA DE ACIERTOS

Mide si al menos un documento relevante aparece dentro de los primeros k resultados. Es un sí o un no por pregunta.

Recall@k EXHAUSTIVIDAD EN K

Mide qué porcentaje de todos los documentos relevantes existentes logró situar el sistema entre los primeros k resultados.

nDCG GANANCIA ACUMULADA DESCONTADA NORMALIZADA

Mide la calidad del ordenamiento completo considerando grados de relevancia; penaliza que los mejores resultados aparezcan tarde en la lista.

Relevancia de la respuesta RAGAS · ANSWER RELEVANCY

El juez genera preguntas a partir de la respuesta y mide su similitud con la pregunta original.

Precision@k PRECISIÓN EN K

Calcula qué fracción de los k resultados devueltos es realmente relevante.

MRR RANGO RECÍPROCO MEDIO

Evalúa en qué posición aparece el primer documento relevante: puntúa al máximo si está en el primer lugar y cae rápidamente si aparece más abajo.

Fidelidad RAGAS · FAITHFULNESS

Proporción de afirmaciones de la respuesta que se pueden deducir del contexto recuperado.

Precisión del contexto RAGAS · CONTEXT PRECISION

Mide si los fragmentos útiles aparecen en los primeros puestos del contexto entregado al modelo.

Glosario de conceptos

LLM como juez

Un modelo de lenguaje evalúa las respuestas con criterios definidos. Orienta la mejora; no certifica, y se complementa con métricas deterministas.

Conjunto dorado **GOLDEN SET**

Banco de preguntas con respuesta, ruta y fuentes conocidas que actúa como examen reproducible del asistente.

RAG **GENERACIÓN AUMENTADA POR RECUPERACIÓN**

El modelo responde a partir de fragmentos recuperados de una base documental, no de su memoria, y cita la fuente.

Embeddings

Vectores numéricos que representan el significado de un texto; permiten buscar por similitud semántica en una base vectorial.

Re-ranker **CROSS-ENCODER**

Modelo que reordena los candidatos de la búsqueda evaluando pregunta y fragmento juntos; más preciso y más costoso que la búsqueda inicial.

Abstención

El agente declara que no tiene evidencia suficiente y ofrece derivar a una persona, en lugar de inventar una respuesta.