

# Agente operativo con IA y RAG para consultas de stock, pedidos, políticas y reportes

Propuesta de solución, arquitectura de integración, selección tecnológica y prueba de concepto funcional

Jefferson Cuadrado  
Octubre de 2026



Prueba de concepto: dato vivo del ERP, política citada y veredicto en una sola respuesta

## Cuatro bloques, de la necesidad de negocio a la prueba de concepto

01

### Propuesta de Solución

*¿Qué problema de negocio resolvemos y con qué enfoque?*

Problema, impacto y propuesta de agente con RAG

4 min

02

### Arquitectura e Integración

*¿Cómo interactúan usuario, agente, conocimiento y ERP?*

Arquitectura de referencia, flujo BPMN e integración con el ERP

6 min

03

### Selección Tecnológica & Agentes

*¿Con qué tecnología y cómo se evitan las alucinaciones?*

Frameworks, modelos, prompt engineering y evaluación

6 min

04

### Demostración Práctica (PoC)

*¿Funciona con servicios reales y con qué resultados?*

Atlas en vivo, escenarios, métricas y ruta a producción

7 min

*Las secciones 1 a 3 describen la solución como propuesta de arquitectura; la sección 4 presenta Atlas, la prueba de concepto que la materializa*

# 01

## Propuesta de Solución

El problema de negocio, su impacto y una solución estructurada basada en un agente de IA con RAG

1 · Propuesta de Solución

2 · Arquitectura e Integración

3 · Selección Tecnológica & Agentes

4 · Demostración Práctica (PoC)

# Las consultas manuales convierten a los expertos en un cuello de botella

## Cuatro tipos de consulta, dos naturalezas de fuente

### Stock de productos

#### Dato transaccional vivo

ERP · inventario por bodega

### Estado de pedidos

#### Dato vivo y con propietario

ERP · pedidos e historial

### Validación de políticas

#### Conocimiento normativo

Documentos versionados

### Resúmenes de reportes

#### Agregación de datos

ERP · ventas y operaciones

### Causa raíz

Cada respuesta exige combinar datos que cambian a cada minuto con normas estables, y hoy solo una persona sabe dónde buscar ambos y qué puede ver cada solicitante

## Impacto actual

**Demora** respuestas en horas, atadas a la disponibilidad de quien sabe buscar

**Inconsistencia** la misma pregunta recibe respuestas distintas según quién responda

**Sin trazabilidad** no queda registro de qué se respondió, con qué fuente ni a quién

**Coste de oportunidad** perfiles expertos dedicados a consultas repetitivas

## Objetivos medibles (línea base supuesta)

**≤ 8 s**

respuesta p95

hoy 2 a 4 h

**≥ 80 %**

sin intervención

hoy 0 %

**100 %**

datos vivos exactos

hoy sin medir

# Un agente orquestador responde cada consulta desde su fuente de verdad

## No todo es RAG: cinco rutas según la evidencia necesaria

### DATA

#### Herramientas sobre el ERP

«¿Cuánto stock queda del producto X en la bodega principal?»

### RAG

#### Políticas con cita verificable

«¿Cuál es el plazo para devolver un producto con defecto?»

### MIXED

#### Dato vivo + política

«¿Todavía puedo devolver mi pedido?»

### DIRECT

#### Sin datos de negocio

Saludos y preguntas sobre el propio asistente

### ABSTAIN

#### Sin evidencia: deriva

«¿Cuál es la política de teletrabajo para proveedores?»

## Componentes de la solución

1

#### Agente orquestador

un solo agente enruta, reúne evidencia, redacta y verifica

2

#### Herramientas sobre el ERP

consultas tipadas con los permisos del solicitante

3

#### RAG sobre políticas

búsqueda semántica en documentos versionados, con cita

4

#### Abstención y derivación

sin evidencia suficiente, lo declara y escala a una persona

5

#### Canales y trazabilidad

web y mensajería con el mismo agente; cada turno se registra

**Principio rector** el LLM no es la fuente del dato: enruta, razona sobre evidencia recuperada y redacta. Cifras desde el ERP; normas desde documentos citados

# 02

## Arquitectura e Integración

Cómo interactúan el usuario, el agente, la base de conocimiento y las APIs del ERP

1 · Propuesta de Solución

2 · Arquitectura e Integración


3 · Selección Tecnológica & Agentes

4 · Demostración Práctica (PoC)

## La arquitectura separa canales, orquestación, conocimiento y ERP



# Cada turno decide su ruta, reúne evidencia y se verifica antes de responder



## Un grafo de estados en código gobierna cada turno y llama al LLM solo dos veces



Un solo LLM, dos llamadas por turno (peor caso cuatro); LangGraph controla el flujo, los topes y los reintentos

# El ERP se integra con herramientas tipadas tras un gateway, no con Text-to-SQL

## Patrón de integración en capas



Cambiar de ERP es escribir otra implementación del gateway: herramientas, prompts y grafo no cambian

## Herramientas tipadas frente a Text-to-SQL

| Criterio     | Herramientas tipadas                   | Text-to-SQL                                   |
|--------------|----------------------------------------|-----------------------------------------------|
| Permisos     | los aplica el servidor en cada llamada | dependen de la consulta que escriba el modelo |
| Seguridad    | argumentos validados; sin SQL generado | superficie de inyección y fuga entre clientes |
| Exactitud    | cálculos deterministas en el servicio  | cifras sujetas a errores de la consulta       |
| Auditoría    | llamada y argumentos en la traza       | consultas libres, difíciles de revisar        |
| Flexibilidad | acotada al catálogo de herramientas    | alta, para analítica exploratoria             |

**Decisión** herramientas tipadas para la operación; Text-to-SQL solo como evolución para analítica, sobre una réplica y con un rol de solo lectura

# 03

## Selección Tecnológica & Agentes

Frameworks, modelos y estrategias de prompt engineering y orquestación para respuestas precisas

1 · Propuesta de Solución


2 · Arquitectura e Integración

3 · Selección Tecnológica & Agentes

4 · Demostración Práctica (PoC)

# LangGraph aporta el control explícito del flujo que exige un agente auditable

## Matriz ponderada (1 a 5) · valoración para este caso



## Criterios y pesos

- |                                         |                                         |
|-----------------------------------------|-----------------------------------------|
| 25 % Control del flujo y traza por paso | 20 % Integración con backend y permisos |
| 15 % Control fino del LLM               | 15 % Pruebas y versionado               |
| 15 % Pocas piezas móviles               | 10 % Licencia y madurez                 |

## Cada herramienta tiene su lugar

**LangChain / LangGraph**  
grafo de estados explícito, en el proceso del backend, con traza por nodo y pruebas. LangChain aporta los conectores

**LlamaIndex**  
fuerte en ingesta y RAG documental; aquí el reto es la orquestación con el ERP

**CrewAI**  
equipos de agentes colaborativos; un solo agente es más rápido y auditable

**Dify**  
prototipado low-code con RAG; deja permisos y verificación fuera del backend

**n8n**  
automatización e integraciones; útil para notificaciones, no como núcleo del agente

## Modelos acotados y nueve controles cierran el paso a la alucinación

### Modelos

#### LLM de chat

function calling nativo y salida estructurada; en la PoC, gemini-3.5-flash-lite

#### Embeddings

multilingües, 768 dimensiones; gemini-embedding-2

#### Re-ranker

cross-encoder multilingüe en CPU (ONNX), para el modo híbrido

#### LLM juez

evaluación offline; gemini-3.1-flash-lite en el nivel gratuito

*Proveedor intercambiable por configuración: un perfil superior se activa por variables de entorno, tras repetir la evaluación*

### Prompt engineering y orquestación: nueve controles

#### 1 Fuentes separadas

cifras solo de herramientas;  
normas solo del RAG

#### 2 Función forzada

al enrutar, el LLM no responde  
de memoria

#### 3 Salida estructurada

esquema JSON validado antes  
de mostrar

#### 4 Evidencia delimitada

contexto y datos marcados  
como datos, no órdenes

#### 5 Citas literales

cada cita existe en el  
fragmento recuperado

#### 6 Verificación numérica

toda cifra debe estar en la  
evidencia

#### 7 El LLM no calcula

totales, fechas y días los  
calcula el servidor

#### 8 Abstención

sin evidencia suficiente, lo  
declara y deriva

#### 9 Prompts versionados

con ejemplos, en el repositorio  
y evaluados

# La calidad se demuestra con un examen reproducible, no con impresiones

## 1 Conjunto dorado

# 36

preguntas del negocio con  
respuesta conocida

- Ruta esperada por pregunta
- Secciones relevantes por documento
- Valores exactos en las de datos
- 5 sin respuesta: ¿se abstiene?

*Ni preguntas ni umbrales se ajustan  
para aprobar*

## 2 LLM como juez (Ragas)

### Fidelidad

*¿todo lo afirmado se deduce del contexto?*

≥ 0,90

### Relevancia de la respuesta

*¿responde lo que se preguntó?*

≥ 0,85

### Precisión del contexto

*¿los fragmentos útiles aparecen primero?*

≥ 0,80

## 3 Métricas de recuperación

Hit Rate@k

Precision@k

Recall@k

MRR

nDCG

Deterministas, sin LLM: ¿aparece la sección correcta y en qué puesto? Base de una ablación de 24 combinaciones de fragmentación, modo de búsqueda y número de resultados

## 4 Verificación en cada respuesta, también en producción

### Citas

copiadas tal cual del  
fragmento

### Cifras

cada número está en la  
evidencia

### 1.er fallo


se regenera una sola vez

### 2.º fallo

se abstiene y deriva

# La búsqueda densa superó a la híbrida en este corpus y se eligió con datos

Recuperación con fragmentación estructural y k = 5



**Densa:** busca por significado con embeddings. **Híbrida:** suma palabras clave y reordena con un re-ranker

*Ablaciones 63 (densa) y 72 (híbrida con re-ranking), 22 preguntas con secciones relevantes*

Efecto de extremo a extremo (corrida 77 → 78)

|                           |                |
|---------------------------|----------------|
| Exactitud de enrutamiento | 0,833 → 0,889  |
| Datos vivos exactos       | 0,636 → 0,818  |
| Falsa abstención          | 0,226 → 0,161  |
| Latencia p95 del turno    | 17,0 s → 6,0 s |

**Contrapartida declarada** sin re-ranker no hay umbral de corte; la abstención depende de que el generador declare evidencia insuficiente. La híbrida sigue disponible por configuración. La abstención correcta se mantuvo en 1,000 (5 de 5)

# 04

## Demostración Práctica (PoC)

Atlas: la prueba de concepto que materializa la propuesta, con servicios reales y métricas medidas


1 · Propuesta de Solución

2 · Arquitectura e Integración

3 · Selección Tecnológica & Agentes

4 · Demostración Práctica (PoC)

# Atlas materializa la propuesta en un prototipo funcional de extremo a extremo



## Lectura del caso MIXED

**ERP:** entrega el 2026-09-20, 14 días transcurridos. **Política:** plazo general de 30 días, sección 3.1. **Veredicto:** «Cumple», con marca de fecha y hora de la consulta


## De la propuesta a la implementación

| Componente     | En Atlas                                        |
|----------------|-------------------------------------------------|
| Canales        | SPA React y bot de Telegram; correo de respaldo |
| Acceso         | API REST Django 5.2 con JWT y permisos por rol  |
| Agente         | grafo LangGraph de una pasada en el backend     |
| LLM            | gemini-3.5-flash-lite (nivel gratuito)          |
| Vector DB      | PostgreSQL con pgvector (HNSW) e índice léxico  |
| ERP            | ErpGateway sobre un ERP simulado                |
| Observabilidad | panel con trazas, tokens, costo y latencia      |

409 pruebas de backend y 62 de frontend en verde; sin llamadas a la API en la suite por defecto

# Los nueve escenarios del requerimiento se superaron contra servicios reales

| # | Escenario                      | Evidencia                                                |
|---|--------------------------------|----------------------------------------------------------|
| 1 | Stock con datos vivos          | DATA · 142 unidades, iguales a la base, con fecha y hora |
| 2 | Pedido propio y ajeno          | el ajeno responde igual que uno inexistente              |
| 3 | Política con cita              | RAG · sección 5.2, versión 2.0, frase literal            |
| 4 | Devolución con dato y política | MIXED · 14 días, veredicto «Cumple», sección 3.1         |
| 5 | Resumen de ventas a Telegram   | mensaje recibido en el teléfono                          |
| 6 | Tema fuera de la base          | abstención con oferta de derivar                         |
| 7 | Respaldo por correo            | sin Telegram o con el bot bloqueado                      |
| 8 | Intento de inyección           | solo los 6 pedidos del propio cliente                    |
| 9 | Panel de administración        | traza, tokens, costo y latencia por etapa                |



Traza de un turno MIXED en el panel de administración

9 de 9

escenarios superados el 2026-10-04 contra Gemini, Telegram y EmailJS reales; el 2 se repitió tras corregir el desfase horario

## Cumple en fidelidad, recuperación y latencia; tres brechas quedan declaradas

Examen de 36 preguntas · corridas 78 (con juez) y 80 (sin juez)

**0,931**

**Fidelidad**

Cumple · objetivo  $\geq 0,90$

**0,896**

**Relevancia**

Cumple · objetivo  $\geq 0,85$

**1,000**

**Hit Rate@5**

Cumple · objetivo  $\geq 0,90$

**5,1 s**

**Latencia p95**

Cumple · objetivo  $\leq 8$  s

**0,944**

**Enrutamiento**

Brecha · objetivo 0,95 ·  
34/36

**0,909**

**Datos vivos**

Brecha · objetivo 100 % ·  
10/11

**0,799**

**Precisión de contexto**

Brecha · objetivo 0,80

**0,0021**

**USD por pregunta**

tarifa de referencia

### Riesgos y mitigación

#### Inventar datos o políticas

nueve controles y examen con umbrales

#### Inyección de prompts

permisos en el servidor, datos delimitados

#### Cuotas y modelo ligero

perfil superior por variables, tras reevaluar

### Ruta a producción sin cambiar la arquitectura

- ERP real: nueva implementación del gateway (REST u OData)
- SSO corporativo (OIDC o SAML) con roles por grupo
- Colas para ingesta y notificaciones; webhook de mensajería
- Nube gestionada y el examen como puerta en integración continua

Las brechas vienen de controles posteriores al enrutamiento; data-02 se corrigió después y no se ha vuelto a medir. Costo real cero en el nivel gratuito. No se ajustaron preguntas ni umbrales.

IA

# Preguntas

Gracias por su atención. Tres ideas para la conversación:

1

## El LLM no es la fuente del dato

Cifras desde herramientas del ERP; normas con cita verificable

2

## Arquitectura de piezas sustituibles

Agente orquestador, base vectorial y ERP tras un gateway

3

## Medido y con brechas declaradas

Nueve escenarios reales superados y un examen reproducible

## Glosario de métricas de evaluación

**Hit Rate@k** TASA DE ACIERTOS

Mide si al menos un documento relevante aparece dentro de los primeros k resultados. Es un sí o un no por pregunta.

**Recall@k** EXHAUSTIVIDAD EN K

Mide qué porcentaje de todos los documentos relevantes existentes logró situar el sistema entre los primeros k resultados.

**nDCG** GANANCIA ACUMULADA DESCONTADA NORMALIZADA

Mide la calidad del ordenamiento completo considerando grados de relevancia; penaliza que los mejores resultados aparezcan tarde en la lista.

**Relevancia de la respuesta** RAGAS · ANSWER RELEVANCY

El juez genera preguntas a partir de la respuesta y mide su similitud con la pregunta original.

**Precision@k** PRECISIÓN EN K

Calcula qué fracción de los k resultados devueltos es realmente relevante.

**MRR** RANGO RECÍPROCO MEDIO

Evalúa en qué posición aparece el primer documento relevante: puntúa al máximo si está en el primer lugar y cae rápidamente si aparece más abajo.

**Fidelidad** RAGAS · FAITHFULNESS

Proporción de afirmaciones de la respuesta que se pueden deducir del contexto recuperado.

**Precisión del contexto** RAGAS · CONTEXT PRECISION

Mide si los fragmentos útiles aparecen en los primeros puestos del contexto entregado al modelo.

# Glosario de conceptos

## LLM como juez

Un modelo de lenguaje evalúa las respuestas con criterios definidos. Orienta la mejora; no certifica, y se complementa con métricas deterministas.

## Conjunto dorado **GOLDEN SET**

Banco de preguntas con respuesta, ruta y fuentes conocidas que actúa como examen reproducible del asistente.

## RAG **GENERACIÓN AUMENTADA POR RECUPERACIÓN**

El modelo responde a partir de fragmentos recuperados de una base documental, no de su memoria, y cita la fuente.

## Embeddings

Vectores numéricos que representan el significado de un texto; permiten buscar por similitud semántica en una base vectorial.

## Re-ranker **CROSS-ENCODER**

Modelo que reordena los candidatos de la búsqueda evaluando pregunta y fragmento juntos; más preciso y más costoso que la búsqueda inicial.

## Abstención

El agente declara que no tiene evidencia suficiente y ofrece derivar a una persona, en lugar de inventar una respuesta.